

情報技術者(民間資格)3 G検定

機械学習の基礎

第3回 / 90分

今日の到達目標

- 特徴量と正解データを, 具体例で説明する.
- 学習と推論で, 何をしているかを区別する.
- 教師あり・教師なし・強化学習の違いを説明する.
- 未知のデータで評価する理由と, 過学習を説明する.

今日は, 機械学習の全体の流れをつかむ.

全15回の中での位置

回	主な内容
1～2	AIの概要・歴史／探索・知識を使う方法
3～4	機械学習の基礎／代表的な手法と評価
5～9	深層学習／画像・言葉／生成AI
10～12	AIの応用・開発／実習2回
13～15	法律・倫理／総復習

今日: データから学ぶ流れ → 次回: モデルと評価を具体的に見る

前回の復習：ルールを書く方法との違い

比較点	ルールベース	機械学習
例：迷惑メール判定	人が判定条件を書く	例から判定モデルを学ぶ
判断の基準	明示した規則	学習で調整したモデル
準備するもの	知識・事実・規則	目的・データ・学習方法

機械学習でも、目的とデータの設計は必要.

機械学習：データからモデルを調整する



- 例から，入力と出力の関係やデータの構造を捉える.
- 学んだモデルを，新しい入力に使う.
- 目的に合うデータと，結果の確認が必要.

「データを保存する」だけで，学習したことにはならない.

特徴量と正解：翌日のパンの販売数を予測する

特徴量：予測するときに分かる情報

正解：後で確定

曜日	気温予報(°C)	前日の販売数	対象日の販売数
月	20	80	85
火	22	85	90
土	25	90	120

特徴量 → モデル → 予測した販売数

最初に決めること: 入力・出力・使う時点

- 何を予測したいか: 翌日の販売数? 売り切れるか?
- いつ予測を使うか: 仕込みを始める前?
- その時点で何が分かるか: 曜日・予報・過去の実績?
- どう確かめるか: どれくらい予測が外れるか?

手法を選ぶ前に, 解きたい問題を具体化する.

学習と推論：モデルを作るときと使うとき

学習：入力と正解を使って、モデルを調整する



推論：調整したモデルに、新しい入力を与える



学習の種類: どんな情報が与えられるか

種類	学習時の手がかり	代表的な目的
教師あり学習	入力に対応する正解	分類・数値の予測
教師なし学習	正解なしのデータの構造	グループ分け・構造の発見
強化学習	行動の結果としての報酬	行動の選び方を改善

「どの情報から学ぶか」に注目する.

教師あり学習：分類はカテゴリを予測する



- 学習時には、メールと正解カテゴリの組を用意する.
- 出力は、あらかじめ決めたカテゴリ.
- 例：画像の種類，不良品か良品か，問い合わせの種別.

分類の問い：「どのカテゴリに属するか？」

教師あり学習：回帰は数値を予測する



- 学習時には、入力と実際の数値の組を用意する.
- 出力は、販売数・時間・金額などの数量.
- 予測値と実際の値との差で、外れ方を確かめる.

回帰の問い:「どれくらいの数量か？」

演習1: 分類か, 回帰か

- ① 配送に何分かかるかを予測する.
- ② 手書き画像が, 0~9のどの数字かを判定する.
- ③ 明日, パンが何個売れるかを予測する.
- ④ メールが迷惑メールか通常メールかを判定する.


判断の理由を, 「何を出力するか」で説明する.

演習1: 解答

問題	答え	出力
① 配送時間	回帰	何分という数量
② 手書き数字	分類	0～9というカテゴリ
③ パンの販売数	回帰	何個という数量
④ メールの判定	分類	迷惑／通常というカテゴリ

数字で表すカテゴリもある。数量を求めるかどうかで考える。

モデルの例：点の傾向に合わせて線を引く



黒い点：過去の例

赤い線：予測モデル

予測値 $= 10x + 20$

※架空の数値による模式図。赤線はモデルの例。

演習：予測の外れ方を比べる

モデルA: 予測値 = $10x + 20$ / モデルB: 予測値 = $20x + 10$

入力 x	正解 y	予測A(差の大きさ)	予測B(差の大きさ)
1	28	30(2)	30(2)
2	44	40(4)	50(6)
3	48	50(2)	70(22)
合計	—	差の合計:8	差の合計:30

このデータではAの誤差が小さい。別のデータではどうだろう？

教師なし学習：正解の区分を与えず構造を探す




- クラスタリング：似たデータをグループに分ける.
- 次元削減：多くの特徴量を，少ない表現にまとめる.
- 見つけた構造が役立つかを，目的に照らして確認する.

「正解ラベルなし」と「何も設計しない」は別.

クラスタリングの例：顧客をグループに分ける

1回の購入額



購入頻度

※架空データを2群に分けた模式例。色は分けた結果を示す。

正解のグループ名を
先に与えていない。

特徴量をもとに
似た例をまとめる。

強化学習: 行動の結果から選び方を改善する



例: 迷路のゴールで+10, 移動1回ごとに-1(教材用)

一回の行動だけでなく, その後の報酬も考える.

三つの学習方法を, 同じ観点で比べる

比較点	教師あり	教師なし	強化学習
主な手がかり	入力と正解の組	正解なしの構造	行動の結果の報酬
目指すこと	出力を予測する	構造を見つける	行動の選択を改善
例	販売数の予測	顧客のグループ分け	ゲームや制御

学習の種類は, 「何を与えて, 何を学ばせるか」で判断する.

演習2: どの学習方法を使うか

- A 製品画像と「良品／不良品」の正解を集め、新しい製品画像の判定を学ぶ.
- B 顧客の購買履歴から、似た顧客をまとめる. 正解のグループ名は与えない.
- C 仮想の倉庫で配送ロボットを動かし、移動の結果の報酬から行動の選び方を改善する.

答えに加えて、判断の手がかりを一つ挙げる.

演習2: 解答

事例	学習の種類	判断の手がかり
A 製品の判定	教師あり学習	入力と正解カテゴリの組
B 顧客をまとめる	教師なし学習	正解のグループ名を与えない
C ロボットの行動	強化学習	行動の結果としての報酬

学習方法と、モデルの種類は別の観点.

汎化: 学習に使っていないデータでも役立つか



- 学習に使った例で良い結果が出ても、それだけでは足りない.
- 実際に使う場面に近い, 別のデータで確かめる.
- データの季節・対象・条件が変わる影響も考える.

目的は、「見たことのある例を覚えること」だけではない.

データを分ける: 訓練・検証・テスト



訓練: 1～6
モデルを学習

検証: 7～8
モデル・設定を選ぶ

テスト: 9～10
最後に評価

比率は説明用の例. 分け方はデータの性質と利用場面に合わせる.

テストデータを見ながら, モデルの設定を調整し続けない.

過学習：訓練データに合わせすぎる

モデル	訓練データの正解率	検証データの正解率
A	99%	68%
B	91%	88%

- Aは訓練データで高精度だが、検証データで大きく低下.
- 未知のデータに対する結果も見て、モデルを選ぶ.

※架空の数値による模式例.

単純すぎても、複雑すぎても難しい

状態の例	訓練での誤差	検証での誤差
単純すぎて傾向を捉えない	大きい	大きい
データの傾向をうまく捉える	小さい	小さい
訓練の細部に合わせすぎる	非常に小さい	大きい

訓練と検証の両方を見て、モデルの適合を考える。

データの品質と、予測時に使える情報

- 欠損や誤った正解があると、学習や評価に影響する.
- 一部の季節・利用者だけのデータでは、偏りが生じる.
- 予測するときに入手できない情報を、入力に混ぜない.

販売予測の例

前日には分からない「対象日の閉店後の在庫」は使えない.

最終確認: 学習方法と評価の理由を説明する

- ① 過去の実績から, 明日のパンの販売数を予測する.
どの学習方法・どのタスクか?
- ② 正解の区分を与えず, 顧客を似たグループに分ける.
どの学習方法か?
- ③ 訓練データで高精度だった. この結果だけで,
実際に使っても良いと判断できるか?

最終確認：解答

- ① 教師あり学習の回帰：実際の販売数を正解として学ぶ.
- ② 教師なし学習：正解の区分なしでグループを探す.
- ③ 訓練結果だけでは判断できない.
学習に使っていないデータと、実際の利用条件で確認する.

今日のまとめ

問い	考えること
何を予測・発見したい？	入力・出力・使う時点を決める
何を手がかりに学ぶ？	正解・データの構造・報酬を区別する
新しいデータでも役立つ？	訓練・検証・テストを分け, 結果を比べる

データ → 学習 → 推論 → 評価, という流れを説明する.

振り返りと次回

- 身近な課題を一つ選び，入力と出力を書いてみる.
- 教師あり・教師なし・強化学習のどれが合いそうか？
- 学習に使っていないデータで，何を確かめたいか？

次回：代表的な機械学習手法と評価
モデルの特徴と，予測の良さの測り方を具体的に学ぶ.

参考資料1:機械学習の基本

- [Google:What is Machine Learning?](#)
- [Google:Supervised Learning](#)
- [Google:Linear regression](#)
- [scikit-learn:Clustering](#)
- [Sutton & Barto:Reinforcement Learning, 2nd ed.](#)

確認日:2026年10月7日／詳しいリンクは各スライドのノートにも記載

出典リンク:各項目をクリック／講師用ノートにも記載

参考資料2: 汎化・データ分割・過学習

● [Google: Generalization](#)

● [Google: Dividing the original dataset](#)

● [Google: Overfitting](#)

● [scikit-learn: Common pitfalls](#)

講義計画: `lecture-plan.md`

詳細な試験範囲: `g-kentei-syllabus.md`