

情報技術者(民間資格)4 G検定

代表的な機械学習手法と評価

第4回 / 90分 / 全25枚

今日の到達目標

- 代表的なモデルの特徴を，入力・出力と結び付ける.
- 決定木を，条件の分岐に沿ってたどる.
- 回帰の誤差と分類の評価指標を，小さな例で計算する.
- 目的に合う指標を選ぶ理由を説明する.

モデルの名前と，評価の目的を一緒に考える.

第3回の復習: 学習方法・モデル・評価は別の観点


観点	例
学習で何を与えるか	正解付きの例 → 教師あり学習
何を出力したいか	数量 → 回帰／カテゴリ → 分類
どんなモデルを使うか	線形回帰・決定木など
どのように確かめるか	未知のデータで誤差や正解率を測る

今日は「モデル」と「評価」を具体化する。

今日扱う手法の見取り図

やりたいこと	代表例	出力
数量を予測	線形回帰	販売数・時間など
カテゴリを判定	ロジスティック回帰	良品／不良品など
条件で分けて予測	決定木・木の組合せ	カテゴリや数量
似た例をまとめる	クラスタリング	グループ
特徴量をまとめる	主成分分析 (PCA)	少ない成分の表現

線形回帰: 数量を予測する関係を学ぶ



予測値 $= wx + b$


w : 傾き

b : 切片

この例: $10x + 20$

傾きと切片を, データから学習する.

ロジスティック回帰: 分類に使う




0~1の値を出す.

閾値でカテゴリを
決める.

例: 0.5以上なら
「不良」と判定.

「回帰」という名前でも, 分類に使うモデル.

決定木: 条件をたどって予測する



教材用の分類木. 実際には分岐をデータから学ぶ. 回帰にも使える.

演習1: 前ページの決定木をたどる

休日か？ → 平日なら、気温予報が25℃以上か？

ケース	休日か	気温予報	予測は？
A	平日	20℃	？
B	平日	27℃	？
C	休日	18℃	？

答えに加えて、通った分岐を説明する.

演習1: 解答

ケース	分岐の経路	予測
A	平日 → 気温25℃未満	少ない
B	平日 → 気温25℃以上	多い
C	休日 → そのまま葉へ	多い

Cは、この木では気温の分岐を通らない。

アンサンブル: 複数のモデルを組み合わせる

木1: 多い

木2: 少ない


木3: 少ない

多数決の模式例 → 少ない

代表例	大まかな考え方
ランダムフォレスト	多様な決定木を組み合わせる
ブースティング	前の誤りを補うよう、モデルを順に加える

分類では多数決・確率の平均など、回帰では平均などでまとめる。

クラスタリング: 似た例をまとめる




例: k-means

群の数 k を決める.

近い中心への割当てと
中心の更新を繰り返す.

正解のグループを与えず, データの構造を探す.

次元削減: 特徴量を少ない成分で表す



主成分分析 (PCA)

分散が大きい方向を
新しい軸にする.

この例: 2次元 → 1次元

情報の一部は失われる. 特徴量の尺度にも注意する.

モデル選択：出力とデータに合う候補を比べる

候補	主な用途	比べる観点の例
線形回帰	数量の予測	誤差・関係の読み取り
ロジスティック回帰	分類	分類指標・閾値
決定木	分類・回帰	誤差・深さ・解釈
木のアンサンブル	分類・回帰	精度・処理量
クラスタリング	グループの発見	群のまとまり・利用目的
PCA	少ない成分の表現	残る情報・利用目的

名前だけで選ばず、同じ条件で候補を比較する。

評価の準備: 未知のデータで, 同じ条件で比べる

訓練データ
モデルを学ぶ

検証データ
候補・設定を選ぶ

テストデータ
最後に確かめる

- **候補の比較**には, 同じ分割・同じ指標を使う.
- **テスト結果**を見て, 何度も設定を選び直さない.

交差検証: 訓練・検証の担当を交代させ, 複数回評価する方法.

回帰の評価：予測と実際の差を測る

実際の販売数	予測の販売数	差(予測-実際)	差の二乗
10	12	2	4
20	18	-2	4
30	36	6	36

MAE(平均絶対誤差) = $(2 + 2 + 6) \div 3 \approx 3.33$ 個

RMSE(二乗平均平方根誤差) = $\sqrt{(44 \div 3)} \approx 3.83$ 個

RMSEは、大きな誤差の影響を受けやすい。

分類の評価：混同行列で数える

200個の製品を検査。「不良」を陽性(+)とする。

実際 \ 予測	不良と予測(+)	良品と予測(-)
実際：不良(+)	30(TP)	10(FN)
実際：良品(-)	20(FP)	140(TN)

FN: 不良の見逃し / FP: 良品を不良とする誤検知

正解率: 全体のうち, 正しく判定した割合

正解率 = 正しい判定の数 ÷ 全体の数

$$(TP + TN) \div 200 = (30 + 140) \div 200 = 85\%$$

- 全体の正解の多さを, 一つの数で表す.
- どの種類の誤りが多いかは, この数だけでは分からない.

正解率だけで十分？ クラスの偏りに注意する

実際：良品 990個

実際：不良 10個

全て「良品」と予測すると.....

正解率 99%

不良品10個を、全て見逃している.

適合率と再現率：分母の違いを押さえる

適合率：不良と予測した中で、実際に不良だった割合

$$TP \div (TP + FP) = 30 \div 50 = 60\%$$

再現率：実際の不良のうち、見つけた割合

$$TP \div (TP + FN) = 30 \div 40 = 75\%$$

補足： $F1 = 2 \times \text{適合率} \times \text{再現率} \div (\text{適合率} + \text{再現率}) \approx 66.7\%$

演習2: 正解率・適合率・再現率を計算する

製品100個. 不良を陽性(+)として, 三つの指標を求める.

実際 \ 予測	不良と予測(+)	良品と予測(-)
実際: 不良(+)	8(TP)	2(FN)
実際: 良品(-)	4(FP)	86(TN)

それぞれの「分母」は, 何を数えているか?

演習2: 解答

指標	計算	結果
正解率	$(8 + 86) \div 100$	94%
適合率	$8 \div (8 + 4)$	約66.7%
再現率	$8 \div (8 + 2)$	80%
F1(補足)	$16 \div 22$	約72.7%

「予測した不良」と「実際の不良」を区別する.

閾値と目的: どの誤りを減らしたいか

閾値を下げる
不良の判定を広げる

閾値を上げる
不良の判定を絞る

- 見逃しを減らすと, 良品の追加検査が増える場合がある.
- 見逃しの損失と誤検知の手間を, 目的に合わせて考える.
- 閾値は検証データで選び, テストで最後に確かめる.

まとめ・振り返り

観点	今日の要点
モデル	求める出力と、データの性質に合う候補を考える
評価	回帰は誤差, 分類は目的に合う指標を使う
確認	同じ条件で比べ, 未知のデータで確かめる

不良の見逃しを減らしたいとき, 何を確認する？

次回:ニューラルネットワークと深層学習

参考資料1: 代表的なモデル

[1. Google: Linear regression](#)

[2. Google: Logistic Regression](#)

[3. scikit-learn: Decision Trees](#)

[4. scikit-learn: Ensembles](#)

[5. scikit-learn: Clustering](#)

[6. scikit-learn: Principal component analysis](#)

各項目をクリックすると、公式資料を開く。

参考資料2: 評価方法

[1. scikit-learn: Metrics and scoring](#)

[2. Google: Accuracy, recall, precision and F1](#)

[3. Google: Dividing the original dataset](#)

[4. scikit-learn: Tuning the decision threshold](#)

図・数値・演習: 本講義の作例 / 公式試験問題ではない.