

情報技術者(民間資格)14 G検定

AI倫理とガバナンス

第14回 / 90分 / 全25枚

今日の到達目標

- 精度以外に, AIが人へ与える影響を挙げる.
- 公平性・透明性・安全性の確認方法を考える.
- 担当・記録・見直しを, 運用へ組み込む.

法律・倫理・ガバナンス

観点	考えること
法律	制度上の義務や権利を満たすか
倫理	人の尊厳や公平性などに配慮できるか
ガバナンス	誰が判断し、確認し、見直すか

影響を受ける人を考える

- 使う人だけでなく、評価・分類される人も考える.
- 不利益が生じた人が、結果を知り訂正を求められるか.
- 利益と負担が、どの人へ配分されるかを考える.

原則を具体的な確認へつなげる

観点	確認の問いの例
人間中心・公平性	誰の選択や機会に影響するか
安全性・プライバシー	誤りや情報の扱いが害を生まないか
透明性・説明責任	必要な情報を伝え、対応できるか

原則ごとに、実際に確かめることを決める。

偏りが入る場所

場所	起こり得ること
データ収集	特定の人や環境の例が少ない
正解ラベル	過去の判断に偏りが含まれる
モデル・評価	全体の指標で一部の誤りを見落とす
利用・運用	当初と違う対象へ適用する

演習1: 集団ごとの見逃し

架空の集団	適性ありの人数	そのうち推薦した人数
A	20	16
B	20	10

同じ指標を、集団ごとにも確かめる。

演習1: 解答と追加の問い

- Aの再現率 = $16 \div 20 = 80\%$
- Bの再現率 = $10 \div 20 = 50\%$
- 差の原因, ラベルの妥当性, 母数や誤推薦も調べる.

数字の差と, その原因・影響を区別する.

公平性には複数の考え方がある

- 候補にする割合を，集団間で比べる方法がある.
- 適性のある人の見逃しを，比べる方法もある.
- 目的と影響に合わせ，基準と理由を説明する.

属性を消すだけでは解決しない

- 居住地や経歴などが、別の属性の手がかりになる場合がある.
- 正解ラベルや、利用の仕方にも偏りが残る.
- 使う目的と、結果の差を継続して確認する.

プライバシーとデータの必要性

- 目的に必要な情報と、保管期間を決める.
- 組合せによる識別や、出力からの漏えいも考える.
- 便利さと、人の期待や不利益を合わせて見る.

透明性:何を伝えるか

- AIをどこで使っているかを, 必要な相手へ伝える.
- 目的, 主な限界, 想定する利用範囲を説明する.
- 質問や訂正を求める窓口を示す.

モデルの情報を記録する

項目	記録の例
目的・対象	想定する用途と利用者
データ・評価	由来, 期間, 指標, 集団ごとの結果
限界	未確認の条件, 不向きな用途
更新	版, 変更理由, 連絡先

安全性: 失敗を先に考える

- どんな誤りで, 誰にどの程度の害が出るかを考える.
- 想定する環境と, 起こり得る変化で試す.
- 使えない場合の代替手順と, 停止条件を決める.

セキュリティ: AIの前後も守る

- データ, モデル, アカウントのアクセスを管理する.
- 外部資料中の不正な指示や, 情報の持ち出しを考える.
- 権限を絞り, 重要な操作の確認と記録を設ける.


人が確認する仕組みの条件

- 担当者に、判断に必要な情報と時間を渡す.
- AIの結果を訂正・拒否・停止できるようにする.
- AIの答えを、そのまま信じる傾向にも注意する.

説明責任：対応できる体制

- 誰が導入を決め、運用を担当するかを明確にする.
- 判断の根拠と、変更や問題への対応を記録する.
- 提供者と利用者の間で、責任と連絡経路を決める.

ガバナンスを継続する



開発・提供・利用で役割を分ける

主体	担うことの例
開発者	データとモデルを検証し, 限界を記録する
提供者	サービスの条件を示し, 安全に運用する
利用者	用途に合うかを判断し, 出力を確認する

問題が起きたときの対応

段階	行うことの例
把握・抑制	影響と範囲を確かめ、必要な利用を止める
連絡・支援	担当へ連絡し、影響を受けた人へ対応する
分析・改善	原因と対応を記録し、再評価して見直す

演習2:採用支援の利用案を見直す

- 過去の採用記録で学習したAIが、応募者を順位付けする.
- 上位だけを担当者が確認し、不採用の理由は示さない.
- データ, 評価, 人による確認, 問い合わせの対策を考える.

関係者の不利益と, 改善の担当を具体化する.

演習2: 対策の例

問題	対策の例
過去の判断の偏り	ラベルと代表性を調べ, 集団別にも評価する
上位だけを見る	用途を限定し, 見逃しを人が確認する手順を設ける
理由・窓口がない	限界を伝え, 説明と訂正の経路を設ける

対策を提案した後も, 効果確かめる.

まとめ・振り返り

- 精度だけでなく、人への利益と不利益を見る.
- 目的に合う公平性・透明性・安全性を確かめる.
- 担当, 記録, 問い合わせ, 見直しを運用へ組み込む.

次回: 総復習・G検定対策

参考資料1

[1. 経済産業省: AI事業者ガイドライン第1.2版](#)

[2. NIST: AI Risk Management Framework](#)

[3. Google: Machine learning fairness](#)

各項目をクリックすると、参考資料を開く。

参考資料2

[1. Mitchell et al.: Model Cards for Model Reporting](#)

[2. Google: Production ML systems](#)

[3. 個人情報保護委員会: 通則編](#)

各項目をクリックすると、参考資料を開く。